

Projekt SAS Enterprise Miner

Oliwier Laskowski

Lista zmiennych:

loan_id
default
client_id
account_id
attr_age_days
attr_age_years
attr_plec
attr_account_age_days
attr_account_freq
attr_has_card
attr_card_type
attr_card_age_days
attr_card_before_loan
attr_age_at_account_open
attr_balance_at_loan
attr_balance_to_salary
attr_trans_last_90_days
attr_avg_daily_inflow


attr_inflow_outflow_ratio
attr_balance_range
attr_trans_per_day
attr_trans_per_account_day
attr_min_balance_ever
attr_max_balance_ever
attr_loan_to_salary
attr_monthly_burden
attr_loan_duration
attr_payment_to_balance
attr_loan_month
attr_loan_quarter
attr_summer_quarter
attr_age_ratio
attr_account_over_2years
attr_total_inflow_outflow_ratio
attr_total_transactions_before
attr_avg_inflow_before


Parametry drzew:

1. Drzewo decyzyjne 2

Parametry:

- Poziom istotności=0.2
- Maksymalne rozgałęzienie = 2
- Maksymalna głębokość=10
- Wielkość liścia=5
- Ziarno=12345
- Kryterium przedziałowej zmiennej: ProbF
- Kryterium nominalnej zmiennej: ProbChisq







Zmienna celu	Etykieta zmiennej celu	Statystyki dopasowania	Etykieta statystyk	Uczenie	Walidacja	Test
default		NOBS	Suma liczebności	475	207	
default		MISC	Odszetek błędnych klas...	0.056942	0.091787	
default		MAX	Maksymalny błąd bezw...	0.945946	0.945946	
default		SSE	Suma błędów kwadrat...	49.40541	34.16573	
default		ASE	Przeciętny błąd kwadra...	0.052008	0.082326	
default		RASE	Pierwiastek ze średnie...	0.228048	0.287273	
default		DIV	Podzielnik ASE	950	414	
default		DFT	Łączne stopnie swobody	475		

2. Drzewo decyzyjne 1

Parametry:

- Poziom istotności=0.2
- Maksymalne rozgałęzienie = 2
- Maksymalna głębokość=6
- Wielkość liścia=5
- Ziarno=12345
- Kryterium przedziałowej zmiennej: ProbF
- Kryterium nominalnej zmiennej: ProbChisq





Statystyki dopasowania

Zmienna celu	Etykieta zmiennej celu	Statystyki dopasowania	Etykieta statystyk	Uczenie	Walidacja	Test
default		NOBS	Suma liczebności	475	207	
default		MISC	Ośrodek błędnych klas	0.050526	0.072464	
default		MAX	Maksymalny błąd bezw.	0.968059	0.968059	
default		SSE	Suma błędów kwadrat.	41.86953	29.20787	
default		RASE	Przeciętny błąd kwadra.	0.044073	0.07055	
default		RASE	Pierwiastek ze średnie...	0.209936	0.265613	
default		DV	Podzielnik ASE	950	414	
default		DFT	Łączne stopnie swobody	475		

3. Drzewo decyzyjne 3

- Poziom istotności=0.2
- Maksymalne rozgałęzienie = 2
- Maksymalna głębokość=6
- Wielkość liścia=5
- Ziarno=12345
- Kryterium przedziałowej zmiennej: ProbF
- Kryterium nominalnej zmiennej: ProbChisq





Zmienna celu	Etykieta zmiennej celu	Statystyki dopasowania	Etykieta statystyk	Uczenie	Walidacja	Test
default		NOBS	Suma liczebności	475	207	
default		MISC	Odsetek błędnych klas...	0.050526	0.072464	
default		MAX	Maksymalny błąd bezw...	0.993377	0.993377	
default		SSE	Suma błędów kwadrat...	39.67759	23.9573	
default		ASE	Przeciętny błąd kwadra...	0.041766	0.072361	
default		RASE	Pierwiastek ze średnie...	0.204367	0.268999	
default		DIV	Podzielnik ASE	950	414	
default		DFT	Łączne stopnie swobody	475		


Rezultaty na zbiorze walidacyjnym:

1. Macierz klasyfikacji

Tabela klasyfikacji zdarzeń
Wybór modelu w zależności od walidacja: odsetek błędnych klasyfikacji (_VMISC_)

Węzeł modelu	Opis modelu	Rola danych	Zmienna celu	Etykieta zmiennej celu	Fałszywie ujemne	Prawdziwie ujemne	Fałszywie dodatnie	Prawdziwie dodatnie
Tree2	Drzewo decyzyjne (2)	TRAIN	default		24	420	3	28
Tree2	Drzewo decyzyjne (2)	VALIDATE	default		18	182	1	6
Tree3	Drzewo decyzyjne (3)	TRAIN	default		22	421	2	30
Tree3	Drzewo decyzyjne (3)	VALIDATE	default		15	183	.	9
Tree	Drzewo decyzyjne	TRAIN	default		22	421	2	30
Tree	Drzewo decyzyjne	VALIDATE	default		15	183	.	9

2. Krzywa Roc oraz pole pod krzywą



Pole pod krzywą:

Walidacja	Tree	Tree3	Tree2
Indeks ROC	0,691	0,718	0,623

Podsumowanie:

Wszystkie 3 drzewa decyzyjne są oddalone w od przekątnej czyli linii losowej, czyli są w jakimś stopniu lepsze od losowego wyboru. Natomiast nie odchylają się wystarczająco aby uznać je za dobre drzewa decyzyjne. Najlepszym drzewem jest drzewo numer 3. Pole pod krzywą to potwierdza choć jest zbliżone do drzewa 1. Najgorszym drzewem i drzewo numer 2. Modele średnio dopasowały się do danych treningowych, ponieważ wykresy walidacyjne są dużo bliżej przekątnej.

3. True positive rate:

Wzór: $TP/(TP+FN)$

Walidacja	Tree	Tree3	Tree2
True positive rate	0,375	0,375	0,25

4. True negative rate:

Wzór: $TN/(TN+FP)$

Validacja	Tree	Tree3	Tree2
True negative rate	1	1	0,994

Podsumowanie:

Modele 3 i 1 mają takie same dobre wyniki na zbiorze walidacyjnym. Drzewo numer 2 ma zdecydowanie gorsze wyniki jak i na zbiorze treningowym i walidacyjnym. We wszystkich modelach jest mała liczba prawdziwie dodatnich co oznacza że model rzadko wykrywa obserwacje prawdziwie dodatnie. Wyniki na zbiorze treningowym jak i walidacyjnym są podobne więc jest brak przetrenowania modeli. Podsumowując najlepiej sobie radzą drzewa 1 i 3 chociaż i one potrzebują zmian aby je poprawić.